



Fase 3 — Geração de Dados Fictícios

Nesta etapa, criei um script Python para gerar dados fictícios realistas que simulam o ambiente de um escritório contábil com múltiplos clientes.

O objetivo foi criar uma base de dados completa para testar o sistema de auditoria, incluindo **inconsistências propositas** que o motor de regras deverá identificar nas próximas fases.



Objetivo da Fase

Gerar dados fictícios para as 7 tabelas do banco de dados, simulando:

- Empresas clientes do escritório contábil
- Seus clientes e fornecedores
- Movimentações bancárias (extratos)
- Documentos fiscais (NF-e, NFS-e, CT-e)
- Contas a pagar e a receber
- Conciliações entre contas e movimentações

Além disso, incluir **inconsistências propositas** para validar as regras de auditoria que serão implementadas.



Estrutura dos Dados Gerados

Volume de Dados

Tabela	Quantidade
Empresas	10
Clientes	50
Fornecedores	40
Movimentações Bancárias	500
Documentos Fiscais	300
Contas Financeiras	400
Conciliações	112

Distribuição por Empresa

- ~50 **movimentações bancárias** por empresa (extratos de 12 meses)
- ~30 **documentos fiscais** por empresa (NF-e, NFS-e, CT-e)

- ~40 **contas financeiras** por empresa (títulos a pagar e a receber)
- ~60% **das contas pagas** possuem conciliação

Tecnologias Utilizadas

- **Python 3.x**
 - **Pandas** — manipulação e exportação de dados para CSV
 - **Faker** — geração de dados fictícios realistas (nomes, empresas, datas, CNPJs)
-

Inconsistências Propositais

Para testar o sistema de auditoria, incluí as seguintes inconsistências intencionais:

1. Notas Fiscais Duplicadas (~2%)

Algumas chaves de acesso de NF-e aparecem mais de uma vez, simulando emissão duplicada acidental.

Impacto esperado: o motor de regras deve identificar documentos com `chave_acesso` duplicada.

2. Divergências em Valores Pagos (~10%)

Em aproximadamente 10% das contas com status “Pago”, o `valor_pago` é diferente do `valor_original` (valores entre 85% e 95% do original).

Impacto esperado: a auditoria deve sinalizar títulos onde o valor pago diverge do valor original sem justificativa.

3. Conciliações com Diferenças (~15%)

Cerca de 15% das conciliações têm status `Inconsistente`, com diferenças entre o valor da conta financeira e o valor da movimentação bancária.

Impacto esperado: o sistema deve listar todas as conciliações inconsistentes para revisão do contador.

4. Movimentações sem Conciliação (~40%)

Aproximadamente 40% das movimentações bancárias **não** possuem conciliação, ou seja, são entradas/saídas no extrato sem correspondência com títulos registrados.

Impacto esperado: o motor de auditoria deve identificar movimentações bancárias sem correspondência no financeiro.

Como Executar o Script

Pré-requisitos

```
pip install pandas faker
```

Execução

```
cd fiscalaudit-ai
python src/gerador/gerar_dados_ficticios.py
```

Saída

Os arquivos CSV serão gerados em `data/raw/` :

```
data/raw/
├── clientes.csv
├── fornecedores.csv
├── empresas.csv
├── movimentacoes_bancarias.csv
├── documentos_fiscais.csv
├── contas_financeiras.csv
└── conciliacoes.csv
```

Decisões Técnicas

Uso de `random.seed(42)` e `Faker.seed(42)`

Garante que os dados gerados sejam **reprodutíveis** — executar o script novamente produz exatamente os mesmos dados. Isso facilita testes e validações.

CNPJs e CPFs Simplificados

Os CNPJs e CPFs gerados **não** passam pela validação de dígitos verificadores. Para o propósito deste projeto (auditoria de dados financeiros), o formato é suficiente.

Se necessário, uma validação real pode ser implementada futuramente.

Relacionamentos Respeitados

- Documentos de **saída** → vinculados a `clientes`
- Documentos de **entrada** → vinculados a `fornecedores`
- Títulos **a receber** → vinculados a `clientes`
- Títulos **a pagar** → vinculados a `fornecedores`

Isso garante coerência com as regras de negócio definidas na modelagem.

Encoding UTF-8 com BOM

Os CSVs são salvos com `encoding='utf-8-sig'` para garantir compatibilidade com Excel e ferramentas que exigem BOM (Byte Order Mark).



Exemplo de Dados Gerados

Empresa

```
id_empresa,razao_social,cnpj,ramo_atividade,regime_tributario,criado_em  
1,Silva e Rodrigues Ltda,12.345.678/0001-90,Comércio,Simples Nacional,2023-05-12  
14:30:00
```

Movimentação Bancária

```
id_movimentacao,id_empresa,data_movimentacao,tipo_operacao,categoria,descricao_movimentacao,valor_mov  
1,1,2024-08-15,Entrada,Receita de Venda,Recebimento ref. NF 12345,15800.50,1
```

Documento Fiscal

```
id_documento,id_empresa,id_cliente,id_fornecedor,tipo_documento,numero_documento,chave_acesso,data_em  
1,1,23,NULL,NF-e,123456,1234567890123456789012345678901234,2024-08-14,Saída,  
15800.50,Ativa
```



Próximos Passos

Com os dados gerados, as próximas etapas serão:

1. **Fase 4** — Pipeline ETL para carregar os CSVs no MySQL
2. **Fase 5** — Motor de regras de auditoria para identificar as inconsistências
3. **Fase 6** — Análise exploratória dos dados
4. **Fase 7** — Modelo de Machine Learning para detecção de anomalias

Fase concluída! Os dados fictícios estão prontos para alimentar o banco de dados e validar o sistema de auditoria.