



Fase 6 — Análise Exploratória de Dados

Nesta fase criei um notebook Jupyter para explorar visualmente os dados e entender padrões nas inconsistências detectadas pelas regras de auditoria.

A análise exploratória (EDA — Exploratory Data Analysis) é fundamental antes de partir para modelos de machine learning, porque ajuda a entender o que está acontecendo nos dados.



Objetivo da Fase

- Visualizar a distribuição dos dados nas tabelas
 - Analisar padrões nas divergências de pagamento
 - Entender o comportamento das conciliações
 - Identificar empresas com mais problemas
 - Observar tendências ao longo do tempo
-



Tecnologias Utilizadas

- **Jupyter Notebook** — ambiente interativo para análise
 - **Pandas** — manipulação de dados
 - **Matplotlib** — visualizações básicas
 - **Seaborn** — visualizações estatísticas mais bonitas
 - **SQLAlchemy** — conexão com MySQL
-



Análises Realizadas

1. Visão Geral dos Dados

Contagem de registros em cada tabela e visualização em gráfico de barras horizontais.

Resultado:

- 10 empresas
 - 500 movimentações bancárias
 - 289 documentos fiscais (300 originais – 11 duplicatas separadas no ETL)
 - 400 contas financeiras
 - 112 conciliações
-

2. Divergências de Pagamento

Análise detalhada das 23 contas onde o `valor_pago` é diferente do `valor_original`.

Gráficos gerados:

- Histograma da diferença absoluta em R\$
- Histograma do percentual de diferença
- Distribuição por tipo de título (A Receber vs A Pagar)

Descobertas:

- A maioria das divergências está entre 5% e 15% do valor original
 - Tanto títulos a receber quanto a pagar apresentam divergências
 - O total acumulado em divergências é significativo
-

3. Conciliações

Análise do status das conciliações e movimentações não conciliadas.

Gráficos gerados:

- Pizza do status (Consistente vs Inconsistente)
- Distribuição de movimentações não conciliadas por tipo

Descobertas:

- ~12% das conciliações estão marcadas como “Inconsistente”
 - ~78% das movimentações bancárias ainda não foram conciliadas
 - A maioria das movimentações sem conciliação é de entrada
-

4. Análise por Empresa

Identificação de quais empresas concentram mais divergências.

Gráfico gerado:

- Barras com quantidade de divergências por empresa

Descobertas:

- As divergências estão distribuídas entre várias empresas
 - Algumas empresas concentram mais problemas e precisam de atenção especial
-

5. Análise Temporal

Visualização de movimentações bancárias ao longo do tempo (por mês).

Gráfico gerado:

- Barras agrupadas mostrando entradas e saídas por mês

Descobertas:

- O volume de movimentações varia ao longo do ano
 - Entrada e saída seguem padrões relativamente equilibrados
-

6. Documentos Fiscais

Distribuição dos documentos por tipo (NF-e, NFS-e, CT-e, NFC-e) e status (Ativa, Cancelada, Inutilizada).

Gráfico gerado:

- Barras empilhadas mostrando quantidade por tipo e status

Descobertas:

- ~10% dos documentos estão cancelados ou inutilizados
- A distribuição entre os tipos de documento parece balanceada



Como Executar o Notebook

1. Instalar dependências adicionais

```
pip install matplotlib seaborn jupyter
```

2. Subir o Jupyter

```
cd fiscalaudit-ai
jupyter notebook
```

Isso abrirá o Jupyter no navegador.

3. Abrir o notebook

Navegue até `notebooks/analise_exploratoria.ipynb` e execute as células sequencialmente (Shift + Enter).

Importante: o arquivo `.env` precisa estar configurado para o notebook conectar no banco.



Principais Conclusões

Volume de Dados

- Base com 10 empresas, 1.401 registros totais distribuídos nas 7 tabelas
- Volume suficiente para análise e modelagem

Qualidade dos Dados

- As inconsistências propositas da Fase 3 foram confirmadas:
- 23 divergências de pagamento (~10% das contas pagas)
- 13 conciliações inconsistentes (~12%)
- 388 movimentações sem conciliação (~78%)

Padrões Identificados

- Divergências concentradas na faixa de 5-15%
- Algumas empresas concentram mais problemas
- Movimentações não conciliadas são oportunidade de melhoria

Próximos Passos

Com a análise exploratória concluída, as próximas etapas naturais são:

- **Fase 7** — Treinar modelo de Machine Learning para detectar anomalias além das regras fixas
- **Fase 8** — IA Generativa para gerar relatórios em linguagem natural
- **Fase 9** — Dashboard interativo com Streamlit para visualizar tudo de forma amigável